UNIVERSIDAD CUAUHTÉMOC
CAMPUS EN LÍNEA

Maestría en ciencia de datos y procesamiento de datos masivos

Tecnologías avanzadas de bases de datos

Enrique Dávila Gutiérrez
150432

4.1 Proyecto integrador: Evaluación y optimización de una estrategia digital

UNIDAD 4 (SEMANA 4)

Mtro. Isaías Avendaño Cortes

2. A partir de los resultados obtenidos en la Actividad 3.1 y el dashboard de la Actividad 3.2, selecciona un aspecto del entorno digital que pueda mejorarse. Explica el hallazgo que sustenta la oportunidad y relaciónalo con el objetivo de negocio.

3. Plantea una modificación concreta que pueda evaluarse mediante experimentación digital. Define:

a. Elemento o experiencia que se modificará.

b. Versión de control y versión alternativa.

c. Hipótesis de la prueba.

d. Métrica o KPI principal para evaluar el resultado.

e. Segmento de usuarios al que se aplicaría.

f. Criterio que permitiría interpretar los resultados.

2. Aspecto a mejorar y su sustento

Aspecto del entorno digital a mejorar: La experiencia de conversión (Sign Up / Purchase) específica para dispositivos móviles.

Hallazgo que sustenta la oportunidad:

Según los datos de tu análisis, el comportamiento individual (promedios de Bounce Rate, duración de sesión y conversiones) es casi idéntico entre Desktop y Mobile. Sin embargo, al observar los volúmenes totales (la suma), Mobile genera casi el triple de tráfico y conversiones que Desktop (30,911 conversiones móviles vs. 12,963 en escritorio). El hecho de que la tasa de conversión promedio sea plana entre dispositivos indica que no hay una optimización específica que aproveche el enorme volumen de tráfico móvil.

Relación con el objetivo de negocio:

El objetivo es "Mejorar la experiencia del usuario para aumentar la retención y las conversiones". Dado que la gran mayoría de los usuarios navega desde su celular,

reducir incluso una pequeña fracción de fricción en la experiencia móvil (optimizándola más allá del estándar de escritorio) generaría un impacto masivo y directo en el volumen total de conversiones del negocio.

3. Propuesta de experimentación digital (A/B Testing)

a. Elemento o experiencia que se modificará:

El formulario de registro (Sign Up) o el proceso de pago (Purchase) en la interfaz móvil. Específicamente, la simplificación del flujo reduciendo los campos requeridos o habilitando el registro a un clic (ej. Social Login con Google/Apple).

b. Versión de control y versión alternativa:

Versión de control (A): El formulario de registro y flujo de compra actual estándar (el mismo que se utiliza y adapta responsivamente desde Desktop).

Versión alternativa (B): Un flujo optimizado "Mobile-First" que incluye botones flotantes de acción rápida, teclado numérico automático para campos de teléfono/tarjeta y registro con un solo clic (Social Login).

c. Hipótesis de la prueba:

Si simplificamos el proceso de Sign Up y Purchase reduciendo la carga cognitiva y los clics necesarios en pantallas pequeñas, entonces la tasa promedio de conversiones de los usuarios móviles aumentará, porque se eliminará la fricción característica de teclear datos extensos en celulares.

d. Métrica o KPI principal para evaluar el resultado:

KPI Principal: Promedio de conversiones (Conversions mean) por usuario móvil.

KPIs Secundarios: Tasa de abandono en la página específica (para asegurar que el Bounce Rate no aumente).

e. Segmento de usuarios al que se aplicaría:

Usuarios clasificados en el Segmento A (No PC), específicamente aquellos donde la columna Device Category sea igual a Mobile.

f. Criterio que permitiría interpretar los resultados:

Se realizará una prueba de significancia estadística (como un T-Test) tras un periodo de prueba. El criterio de éxito será que la Versión B muestre un aumento estadísticamente significativo en el promedio de conversiones frente a la Versión A, sin impactar negativamente (aumentar) la métrica de Bounce Rate. Si se cumple este criterio, se despliega la nueva experiencia móvil al 100% de los usuarios.

4. Propuesta de modelo predictivo (Machine Learning)

Variable o resultado a predecir (Variable objetivo/Target):

La probabilidad de conversión. Específicamente, predecir si un bloque de tráfico o sesión terminará en una acción clave de alto valor, como "Purchase" (Compra) o "Sign Up" (Registro). Se puede modelar como un problema de clasificación binaria (1 = Convierte, 0 = No convierte/Abandona).

Variables de entrada (Features):

Para que el modelo aprenda los patrones de comportamiento que llevan a una conversión, utilizaría las siguientes columnas disponibles en tu dataset:

De comportamiento:

Avg Session Duration (Duración de la sesión), Page Views (Páginas vistas), Average time on home page (min). Estas son críticas porque a mayor engagement, suele haber mayor probabilidad de conversión.

De contexto tecnológico y de usuario:

Device Category (Mobile, Desktop, Tablet) y la proporción de Returning Users vs New Users.

De adquisición y temporalidad:

Source (Paid search, organic, social media) y Day (Día de la semana, ya que en el análisis exploratorio los viernes y jueves mostraron más conversiones).

Tipo de modelo de aprendizaje automático pertinente:

Dado que queremos predecir una categoría (Convierte o No Convierte) basándonos en datos tabulares estructurados, el enfoque ideal es un modelo de Clasificación Supervisada.

Algoritmos recomendados:

Un Random Forest Classifier (Bosque Aleatorio) o un modelo de Gradient Boosting (como XGBoost).

Estos modelos son excelentes para capturar relaciones no lineales (por ejemplo, si el tráfico móvil convierte mucho más los viernes desde redes sociales que un martes desde tráfico directo). Alternativamente, una Regresión Logística (Logistic Regression) sería un excelente modelo base para entender el peso o importancia exacta de cada variable de forma sencilla.

Herramienta sugerida:

Scikit-learn. Es la librería ideal de Python para este tipo de datos tabulares, ya que permite preprocesar los datos (convertir variables categóricas como Device Category o Source en números usando One-Hot Encoding) y entrenar modelos como Random Forest o Regresión Logística con pocas líneas de código. Aunque TensorFlow se podría usar para construir una red neuronal, para datasets tabulares clásicos de marketing y tráfico web, las herramientas de ensamble de árboles en Scikit-learn suelen ser más rápidas, más fáciles de interpretar y requieren menos configuración.

5. Métricas para evaluar el desempeño de la estrategia

Para determinar si la estrategia de optimización móvil realmente genera un impacto positivo y rentable para el negocio, se deben monitorear las siguientes métricas clave:

Retorno de Inversión (ROI):

Es fundamental para justificar el esfuerzo técnico. Se calcula evaluando si los ingresos incrementales generados por el aumento de conversiones móviles superan el costo de haber desarrollado, implementado y mantenido la nueva experiencia web (la versión B del experimento). Un ROI positivo indica que la fricción eliminada se tradujo en dinero real para la empresa.

Customer Lifetime Value (CLV o Valor del Ciclo de Vida del Cliente):

Dado que el objetivo inicial de negocio incluye "aumentar la retención", el CLV es indispensable. No solo nos interesa saber si el usuario compró o se registró hoy por la facilidad móvil, sino cuánto valor monetario aportará a lo largo de su relación con Amazon. Un proceso de registro (Sign Up) sin fricciones suele atraer usuarios de mayor calidad que regresan a comprar repetidamente.

Costo de Adquisición de Clientes (CAC):

Al mejorar la tasa de conversión, el dinero invertido en fuentes de tráfico (como Paid Search o Social Media) rinde más. Si la estrategia es exitosa, el CAC promedio por usuario móvil debería disminuir, ya que el mismo presupuesto publicitario generará un mayor volumen de usuarios convertidos.

Tasa de Conversión (Conversion Rate) por Dispositivo:

La métrica operativa directa que indicará si el cambio en la interfaz móvil funcionó estadísticamente frente a la versión de escritorio.

6. Asignación de valor a los puntos de contacto (Modelo de Atribución)

En el recorrido del usuario analizado en tu Jupyter Notebook, vemos que los clientes interactúan con diferentes fuentes (Organic, Social Media, Direct) y navegan por distintas secciones (/blog, /products, /home) antes de realizar una acción clave (Purchase, Sign Up).

Modelo de atribución pertinente: El Modelo Basado en la Posición (En forma de U) o un Modelo Basado en Datos (Data-Driven Attribution).

Por qué: Un modelo tradicional de "Último Clic" le daría todo el mérito a la fuente final (ej. Direct), ignorando por completo los canales que generaron el interés inicial (ej. un anuncio en Social Media o una búsqueda en Organic Search). El modelo en forma de U asigna, por ejemplo, un 40% del valor al primer punto de contacto (descubrimiento de la marca), un 20% a las interacciones intermedias (consideración en el /blog o /products) y un 40% al punto de contacto final (el clic que cerró la conversión).

Información que permitiría obtener:

El verdadero rol de cada canal:

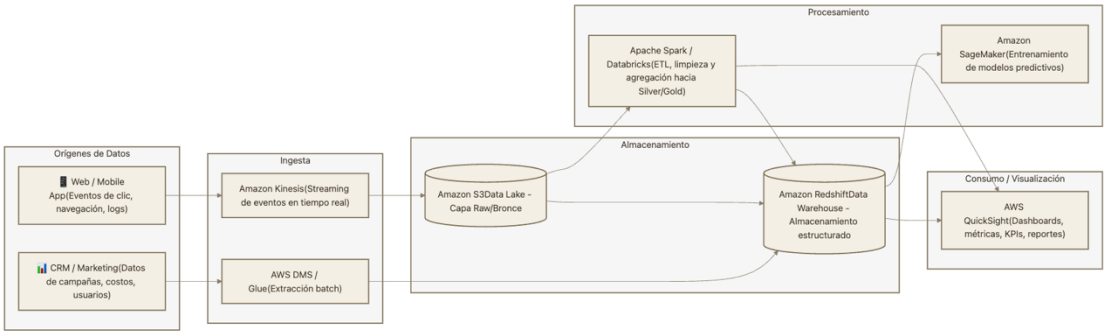
Permitiría descubrir si canales como Social Media (que en la tabla 9 tiene buenas conversiones) actúan principalmente como "asistentes" que inician el recorrido, o como "cerradores" directos de ventas.

Optimización del presupuesto (ROI de Marketing):

Evitaría que el negocio recorte presupuesto en campañas de la parte superior del embudo (Top of Funnel) que parecen no vender directamente, pero que son indispensables para alimentar el tráfico que termina comprando días después mediante búsquedas directas.

7. Flujo general de la solución de analítica en la nube

A continuación se presenta la arquitectura para implementar esta solución a nivel empresarial. El diseño utiliza un enfoque moderno de datos espaciales y analíticos, integrando servicios nativos de la nube (basado en el ecosistema de AWS) y motores de procesamiento de Big Data.



Descripción de las fases:

Recopilación (Ingesta):

Las interacciones del usuario en el sitio web (clics, tiempo en página, dispositivo) se capturan mediante un pixel o SDK y se envían como eventos JSON a un servicio de streaming de alta concurrencia como Amazon Kinesis o Google Cloud Pub/Sub.

Almacenamiento:

Los datos crudos aterrizan inicialmente en un Data Lake altamente escalable y económico, como Amazon S3. Una vez procesados, los datos estructurados y listos para negocio se almacenan en un Data Warehouse como Amazon Redshift o Google BigQuery.

Procesamiento:

Los datos crudos necesitan ser transformados, limpiados y cruzados (ej. unir eventos web con perfiles de usuarios). Aquí se despliegan motores de procesamiento distribuido como Apache Spark (gestionado a través de Databricks o AWS Glue) para ejecutar estas canalizaciones ETL (Extracción, Transformación y Carga) de manera eficiente.

Análisis y Predicción:

Científicos y analistas de datos consumen la información estructurada desde el Data Warehouse para entrenar modelos de Machine Learning (como el Random Forest para predecir conversiones) utilizando entornos como Amazon SageMaker.

Visualización:

Herramientas de inteligencia de negocios como AWS QuickSight o Looker Studio (Google Data) se conectan directamente al Data Warehouse para actualizar los tableros gerenciales en tiempo real, monitoreando el ROI, la tasa de conversión y los resultados de las pruebas A/B.

8. Integración del proceso de optimización

El ciclo de optimización digital no es lineal, sino un bucle de retroalimentación continua donde cada fase detona la siguiente. Los componentes se complementan de la siguiente manera:

Datos:

Es la materia prima pura (logs, tiempos de sesión, categorías de dispositivos). Sin datos centralizados y confiables, las decisiones dependen de la intuición.

Análisis:

Es el proceso de interrogar los datos. A través de la exploración estadística, se transforman los registros individuales en tendencias agregadas (ej. descubrir que el 70% del tráfico es móvil pero su tasa de conversión está estancada).

Hallazgo:

Es el insight o revelación de negocio que surge del análisis. Constituye el problema específico o la oportunidad detectada (ej. existe una alta fricción en el formulario de registro para pantallas pequeñas).

Hipótesis:

Es la solución propuesta basada en el hallazgo. Establece una relación causal que debe comprobarse (ej. si simplificamos el registro con Social Login, entonces aumentarán las conversiones móviles).

Experimentación:

Es el mecanismo científico (Prueba A/B) para validar la hipótesis en el mundo real. Permite mitigar riesgos probando el cambio solo en una fracción del tráfico.

Evaluación:

Es la medición del impacto del experimento utilizando rigor estadístico y métricas de negocio (ROI, CLV, Tasa de Conversión). Determina si la hipótesis fue correcta o si debe descartarse.

Predicción:

Una vez que entendemos qué funciona, aplicamos modelos de Machine Learning para anticipar el comportamiento futuro. Si sabemos qué variables llevan a una conversión, podemos predecir qué nuevos usuarios tienen alta intención de compra.

Optimización:

Es la consolidación de todo el proceso. Se despliega la versión ganadora del experimento al 100% de los usuarios, se enfocan los presupuestos de marketing en los perfiles predecidos como "altamente rentables", y el nuevo estándar del sitio web comienza a generar Datos frescos, reiniciando el ciclo para buscar el siguiente margen de mejora.

9. A partir de los resultados y análisis realizados, presenta recomendaciones para la estrategia digital. Las recomendaciones deberán estar sustentadas en los datos, hallazgos y métricas analizadas.

A partir de los hallazgos del análisis exploratorio, la conceptualización del modelo predictivo y la estrategia de experimentación, las siguientes son las recomendaciones clave para optimizar la estrategia digital del negocio:

1. Transición inmediata a un enfoque de diseño y desarrollo "Mobile-First"

Sustento en datos:

El análisis reveló que el segmento móvil genera 30,911 conversiones, superando ampliamente las 12,963 de escritorio, pero manteniendo una tasa promedio de conversión casi idéntica.

Impacto esperado:

Al implementar flujos de compra a un clic y Social Login para reducir la fricción en pantallas pequeñas, se capitalizará el canal con mayor volumen de tráfico, logrando un aumento directo en el volumen total de conversiones y una mejora en el ROI.

2. Sincronización de presupuestos publicitarios con la temporalidad de conversión

Sustento en datos:

Los resultados exploratorios mostraron que los jueves y viernes presentan picos significativos en el volumen de conversiones.

Impacto esperado:

Se recomienda concentrar la mayor parte del presupuesto de campañas de Paid Search y Social Media (pauta publicitaria) entre los miércoles por la tarde y los viernes. Esto reducirá el Costo de Adquisición de Clientes (CAC) al invertir los recursos exactamente en los momentos de mayor intención de compra comprobada.

3. Implementación de un modelo de atribución Basado en la Posición (Data-Driven)

Sustento en datos:

Los usuarios interactúan con múltiples fuentes (Organic, Social, Direct) y páginas (blog, home, products) antes de convertir. Un modelo de último clic oculta el valor de los esfuerzos de atracción inicial.

Impacto esperado:

Al distribuir el crédito de la conversión (ej. 40% al primer clic, 20% al medio, 40% al cierre), el equipo de marketing digital podrá justificar el presupuesto en canales de "descubrimiento" como redes sociales, asegurando que el embudo de ventas nunca se quede sin tráfico nuevo.

4. Despliegue de analítica predictiva para campañas de retargeting dinámico

Sustento en datos: Se cuenta con variables sólidas (Avg Session Duration, Page Views, Source) que un modelo de clasificación (ej. Random Forest) puede procesar para calcular la probabilidad de conversión de un usuario en tiempo real.

Impacto esperado:

En lugar de lanzar descuentos generales, la plataforma podrá identificar automáticamente a los usuarios de "alta probabilidad que están a punto de abandonar" e impactarlos con incentivos personalizados (ej. envío gratis durante esa sesión), maximizando las conversiones sin erosionar los márgenes de ganancia.

Evidencia 3: Diseño del Experimento (Prueba A/B)

[Nota: El siguiente componente se presenta como una propuesta conceptual para futura implementación en el entorno digital]

1. Título del Experimento:

Optimización del flujo de Conversión (Sign Up / Purchase) para entorno Mobile-First.

2. Justificación (Basada en Datos):

El análisis exploratorio indica que el tráfico móvil (Device Category = Mobile) genera el mayor volumen de conversiones totales (30,911), pero su tasa de conversión promedio por sesión es estadísticamente idéntica a la de Desktop. Esto representa una oportunidad para eliminar fricciones específicas de pantallas pequeñas y maximizar el retorno de este segmento mayoritario.

3. Hipótesis de la Prueba:

Si simplificamos el proceso de registro y compra en dispositivos móviles eliminando campos manuales e introduciendo autenticación rápida, entonces la tasa de conversión promedio móvil aumentará de manera significativa, porque se reduce la carga cognitiva y la fricción de teclear en pantallas pequeñas.

4. Definición de Variantes:

Versión de Control (A):

El flujo de registro y pago actual. Es responsivo, pero requiere llenar manualmente un formulario estándar de múltiples campos (Nombre, Apellidos, Email, Contraseña, etc.).

Versión Alternativa (B):

Nuevo flujo "Mobile-First". Incluye:

Registro e inicio de sesión a un clic (Social Login mediante Google/Apple).

Botones de acción (Call-to-Action) flotantes y siempre visibles ("Comprar ahora").

Activación automática de teclado numérico para campos de tarjeta o teléfono.

5. Segmentación de la Audiencia:

Filtro:

Usuarios con Device Category == 'Mobile'.

Distribución de Tráfico:

50% del tráfico móvil será dirigido a la Versión A (Control) y el 50% a la Versión B (Alternativa) de forma aleatoria.

6. Métricas de Evaluación (KPIs):

Métrica Principal:

Promedio de conversiones (Conversions mean) y Tasa de Conversión (Conversion Rate) por sesión.

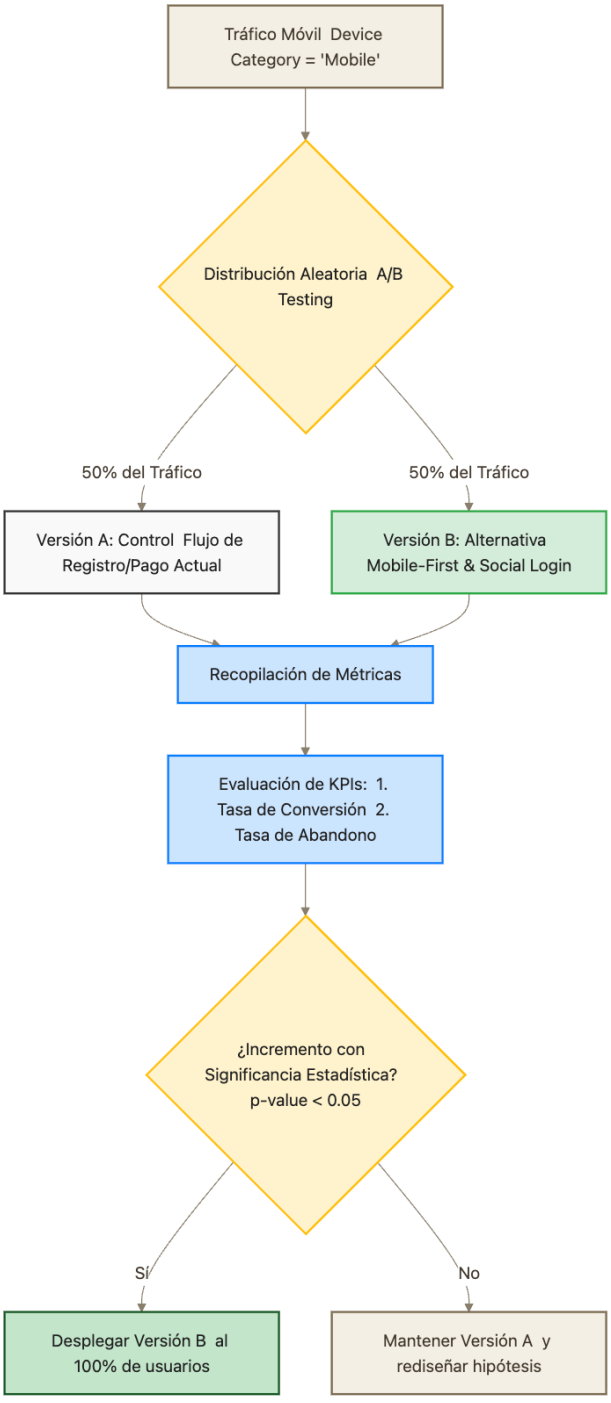
Métrica Secundaria:

Tasa de abandono (Bounce Rate) en la página del carrito/

registro.

7. Criterio de Éxito:

El experimento será exitoso si la Versión B demuestra un incremento en la métrica principal con un nivel de significancia estadística del 95% (p-value < 0.05) sin afectar negativamente la métrica secundaria, tras un periodo de prueba mínimo de 2 a 3 semanas.


Tráfico Móvil Device Category = 'Mobile'
Distribución Aleatoria A/B Testing
50% del Tráfico
50% del Tráfico
Versión A: Control Flujo de Registro/Pago Actual
Versión B: Alternativa Mobile-First & Social Login
Recopilación de Métricas
Evaluación de KPIs: 1. Tasa de Conversión 2. Tasa de Abandono
¿Incremento con Significancia Estadística? p-value < 0.05
Sí
No
Desplegar Versión B al 100% de usuarios
Mantener Versión A y rediseñar hipótesis

UNIVERSIDAD CUAUHTÉMOC
CAMPUS EN LÍNEA